

# Procura Local

- Capítulo 4 Secção 1

# Resumo

- Procura local
- Algoritmos de procura local
  - Hill-climbing
  - Simulated annealing
  - Local beam
  - Genetic algorithms

# Procura Sistemática

- No capítulo 3, analisamos estratégias de **procura sistemática**
  - Exploram sistematicamente caminhos a partir de um estado inicial
  - Guardam um ou mais caminhos em memória
    - Guardam também as alternativas ainda não exploradas em cada ponto de decisão
  - Quando o objectivo é encontrado, o caminho para esse objectivo corresponde a uma solução para o problema

# Procura Local

- Em muitos problemas de optimização, o **caminho** que leva ao objectivo é irrelevante;
  - o próprio estado objectivo é a solução (e.g., n-rainhas)
- Nestes casos, podemos usar **procura local**
  - Mantém um único “estado actual”; caminhos não são memorizados
  - Tipicamente, um estado transita para estados “vizinhos”, substituindo o estado actual

# Procura Local

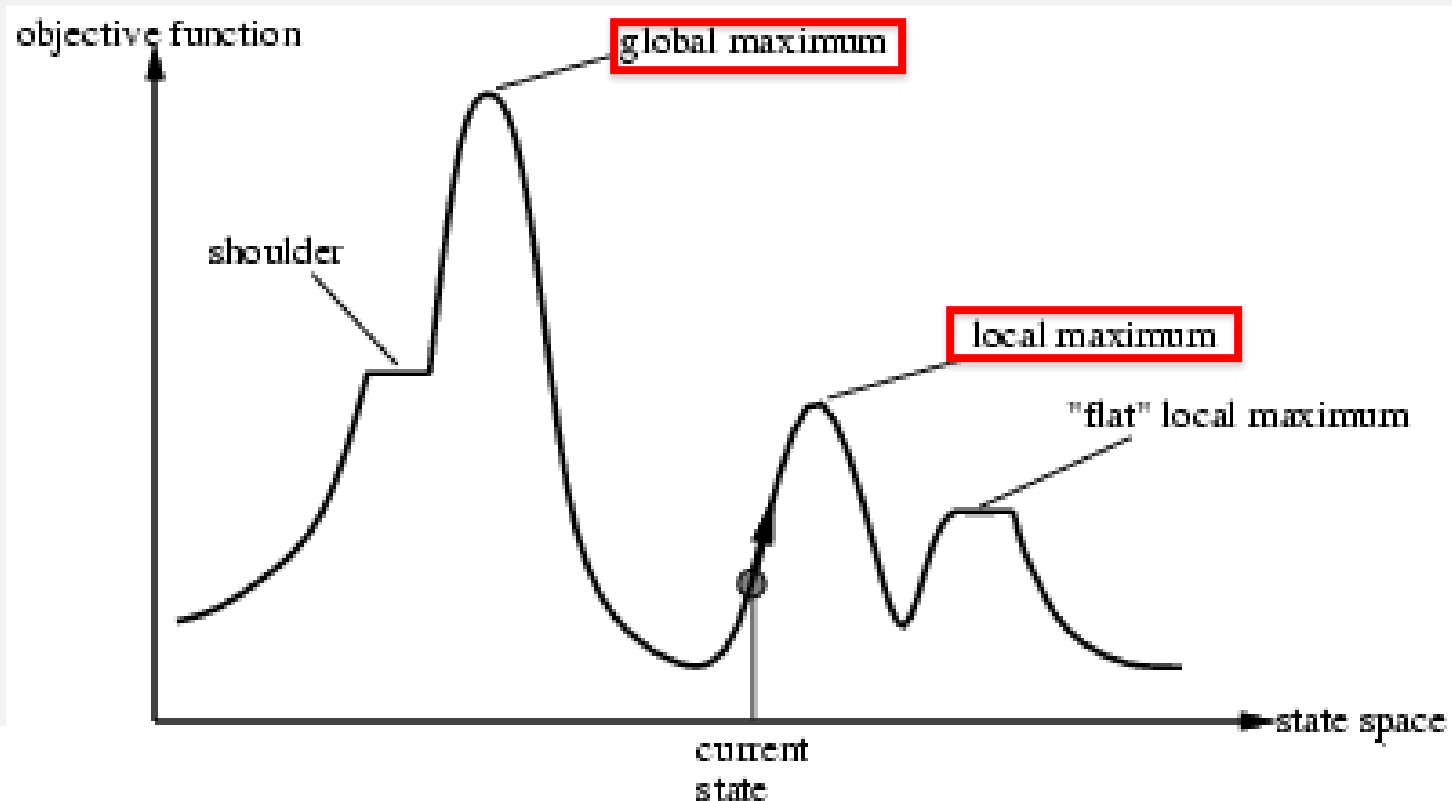
- Vantagens
  - Usam muito pouca memoria (memoria constante)
  - Conseguem encontram soluções em espaços de estados infinitos
    - Procuras sistemáticas não
  - Boas para resolver
    - problemas de optimização
      - Encontrar o estado que maximize/minimize uma função de avaliação
    - problemas de reparação
      - Começamos de um estado inicial completo mas que não satisfaz as restrições do problema
      - Encontrar o estado que satisfaça as restrições, com o mínimo de alterações

# Procura Local

- Desvantagens
  - Não podem ser aplicadas se precisarmos do caminho
  - Não são normalmente completas/óptimas, pois podem ficar presas facilmente em máximos locais

# Procura Local

- Problema: dependendo do estado inicial, pode ficar preso a um máximo local





# Hill-climbing (trepar-a-colina) ou procura local ganaciosa

- É um simples ciclo que se move continuamente na direcção de um valor melhor. Termina quando nenhum sucessor tem valores melhores.
- Não guarda árvore de procura
- Não olha para além dos vizinhos imediatos
- “É como subir o Evereste com nevoeiro cerrado e amnésia” (AIMA)

# Algoritmo Hill-climbing

**function HILL-CLIMBING(*problem*)** returns a state that is a local maximum

***current* ← Make-Node(*problem*.Initial-State)**

**loop do**


***neighbor* ← a highest-valued successor of *current***

**if *neighbor*.Value ≤ *current*.Value then return *current*.State**

***current* ← *neighbor***

# Exemplo: *N-rainhas*

- Problema: Colocar as  $N$  rainhas numa matriz  $n \times n$  de modo que nenhuma esteja em posição de atacar as outras



- Modelado como problema de reparação
  - Estado inicial com uma rainha por coluna gerado aleatoriamente
  - Novos estados gerados a partir de movimentos para estados vizinhos

# Procura com o Hill-climbing no problema das 8 rainhas


- Função sucessor: mexer uma rainha para outra posição na mesma coluna.
- Tipicamente, o Hill-climbing escolhe aleatoriamente entre os melhores sucessores, se houver mais do que um.

# Procura com o Hill-climbing no problema das 8 rainhas

18	12	14	13	13	12	14	14
14	16	13	15	12	14	12	16
14	12	18	13	15	12	14	14
15	14	14	♚	13	16	13	16
♚	14	17	15	♚	14	16	16
17	♚	16	18	15	♚	15	♚
18	14	♚	15	15	14	♚	16
14	14	13	17	12	14	12	18

- $h = n^{\circ}$  de pares de rainhas que se estão a atacar
  - No tabuleiro apresentado:  $h = 17$
  - Num tabuleiro objectivo:  $h = 0$
- Inteiros correspondem ao valor de  $h$  para sucessores resultantes de mover rainha na respectiva coluna ( $\geq 12$ )

# Procura com o Hill-climbing no problema das 8 rainhas



- Mínimo local com  $h = 1$
- Qualquer sucessor tem valor de  $h$  superior

Não encontrou solução e não evoluiu para outro estado...

# Problemas Hill-climbing

- Hill-climbing tem problemas com:
  - Máximos locais – pico mais elevado que todos os seus vizinhos
  - Planaltos – zona do espaço de estados onde a função de avaliação é plana
  - Cumeadas – sequência de máximos locais através dos quais é difícil viajar

# Hill Climbing

- No caso das 8-rainhas
  - Começando num estado aleatório...
    - Só resolve 14% dos casos (necessita em média de 4 iterações)
    - Nos restantes casos fica “parado” ao fim de 3 iterações (em média)
- Como resolver estes problemas?
  - Aleatoriedade :D



# Variantes do Hill Climbing

- **Stochastic Hill climbing**
  - em vez de escolher o melhor nó vizinho
  - escolhe aleatoriamente de entre os vizinhos que melhoram o valor actual
  - probabilidade de selecção varia em função do valor da melhoria
  - Converge mais lentamente para uma solução
  - Mas em certos problemas obtém melhores soluções

# Variantes do Hill Climbing

- **First-choice Hill Climbing**
  - gera os sucessores aleatoriamente um de cada vez
  - se o sucessor gerado for melhor que o nó actual avança para esse sucessor
    - restantes sucessores já não vão ser gerados
  - Ideal para problemas onde o número de sucessores é muito grande ou mesmo infinito
- No entanto, estas duas variantes não resolvem o problema de máximos locais

# Variantes do Hill Climbing

- **Random-restart Hill Climbing:**
  - Se à primeira não conseguimos, tentar de novo
- conduz uma sequência de procura hill-climbing a partir de diferentes estados iniciais
  - gerados aleatoriamente
  - pára quando se encontra o objectivo
- **completa** com probabilidade **perto** de 1
  - eventualmente, se repetirmos vezes suficientes
    - o estado inicial será o estado objectivo
- mas não chega a ser completa com 100% (só no infinito)
  - analogia com o teorema do macaco c/ tempo infinito

# Variantes do Hill Climbing

- **Random-restart Hill Climbing:**
  - Se  $p$  for a probabilidade de sucesso de cada procura Hill-climbing
    - número esperado de tentativas é  $1/p$
  - Exemplo 8-rainhas
    - $P \sim 0.14$
    - Em média são necessárias 7 tentativas (6 falhadas + 1 sucesso)
    - 22 passos para encontrar o objectivo
      - Média de 3 passos por iteração

# Hill Climbing

- Apesar de tudo:
  - Converge (ou não) rapidamente
  - Por exemplo, o Random-restart Hill Climbing consegue encontrar uma solução para as n-rainhas, em menos de um minuto, mesmo para 3 milhões de rainhas.
- Boa quando
  - Espaço de estados com poucos máximos locais e planaltos
  - Random-restart contorna facilmente esses máximos locais
- Em problemas mais complexos
  - Consegue encontrar um máximo local “razoável” ao fim de poucas iterações

# Procura Simulated Annealing

- Em Português: têmpera simulada
- Ideia: escapar ao mínimos locais permitindo que se façam movimentos “maus”, mas vai gradualmente decrementando a sua frequência
  - Escolhe um sucessor aleatoriamente
  - Se o valor do sucessor é melhor que o actual movemo-nos para o sucessor
  - Mas mesmo que seja pior, podemos mover-nos na mesma
    - Com probabilidade  $p < 1$ ,
    - Probabilidade decresce exponencialmente com a má qualidade do movimento  $\Delta E$
    - Probabilidade desce também com temperatura  $T$

# Procura Simulated Annealing

- Valores elevados da Temperatura  $T$ 
  - Maus movimentos são facilmente permitidos
- Valores baixos da temperatura  $T$ 
  - Maus movimentos não são facilmente permitidos
- Consegue-se provar que se temperatura  $T$  diminuir suficientemente devagar (em função do *schedule*), então a procura simulated annealing vai encontrar um máximo global com probabilidade **próxima** de 1
- Analogia com metalurgia (annealing)
  - Processo usado para temperar e endurecer metais e vidros
  - Aquece-se o material a uma temperatura muito alta
  - Deixa-se arrefecer muito devagarinho

# Simulated Annealing

- Metáfora: imaginar a tarefa de pôr uma bola de ping-pong no buraco mais profundo de uma superfície cheia de buracos
- Uma solução é deixar a bola ir parar a um mínimo local e depois abanar a superfície de modo a tirá-la do mínimo local
- Simulated annealing começa por “abanar” muito no início e depois vai abanando cada vez menos



# Simulated Annealing

**function** SIMULATED-ANNEALING(*problem*,*schedule*) returns a solution state

inputs: *problem*, a problem

*schedule*, a mapping from time to “temperature”

*current*  $\leftarrow$  Make-Node(*problem*.Initial-State)

for  $t = 1$  to  $\infty$  do

$T \leftarrow$  *schedule*( $t$ )

    if  $T = 0$  then return *current*

*next*  $\leftarrow$  a randomly selected successor of *current*

$\Delta E \leftarrow$  *next*.Value – *current*.Value

    if  $\Delta E > 0$  then *current*  $\leftarrow$  *next*

    else *current*  $\leftarrow$  *next* only with probability  $e^{\Delta E/T}$

# Local Beam (procura em banda)

- Será que não podemos gastar um pouco mais de memória?
- Ideia: guardar a referência a  $k$  estados, em vez de 1
  - Começa com  $k$  estados gerados aleatoriamente
- Em cada iteração, todos os sucessores dos  $k$  estados são gerados
- Se algum é um estado objectivo, pára; caso contrário escolhe os  $k$  melhores sucessores e repete

# Procura Local Beam

- Atenção que este algoritmo é mais do que correr  $k$  Random-restart Hill Climblings em paralelo!!
  - Não têm de ser escolhidos sucessores de todos os estados
  - Se um estado gera vários bons sucessores e os outros  $k-1$  estados não, os estados menos promissores são abandonados
- No entanto, também pode ter problemas: pode haver pouca diversidade nos  $k$  estados...
  - os  $k$  estados podem facilmente ficar concentrados numa área pequena do espaço de estados

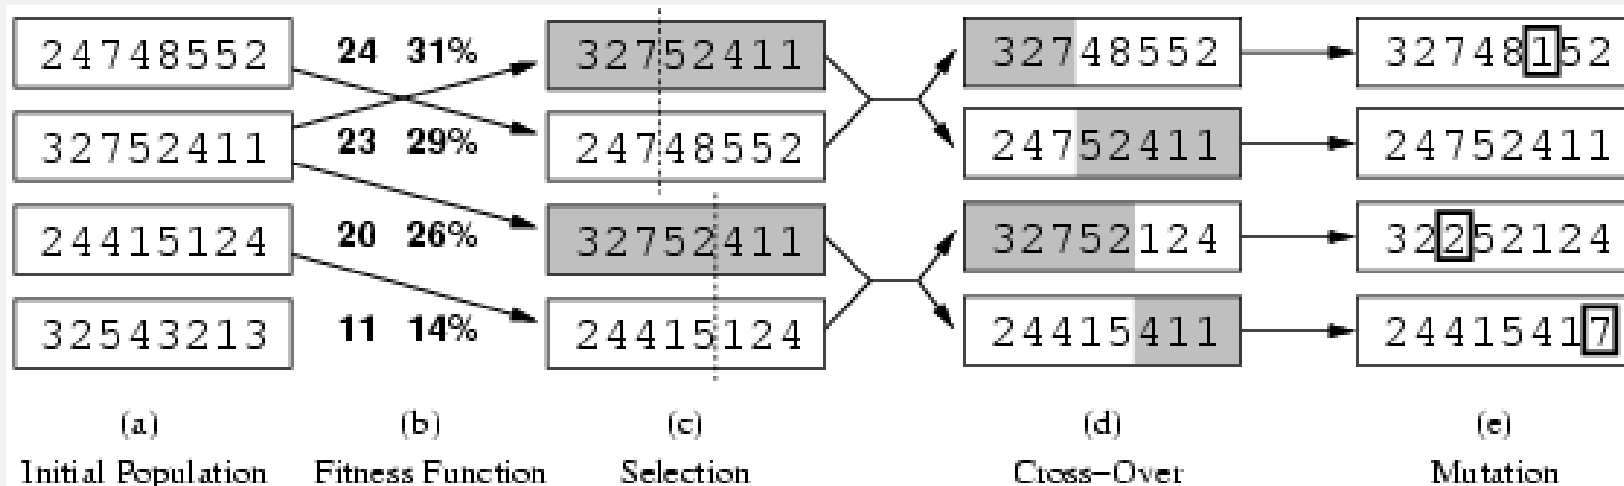
# Procura Stochastic Beam

- **Stochastic Beam Search**
  - Os  $k$  sucessores são escolhidos aleatoriamente
  - Probabilidade da escolha aumenta em função da sua qualidade

# Algoritmos Genéticos


- Variante da stochastic beam search
- Começa com  $k$  estados gerados aleatoriamente (**população**) tal como procura em banda
  - Um estado é representados como uma string sobre um alfabeto finito (geralmente  $\{0,1\}$ )
- O estado sucessor é gerado através da combinação de dois estados (**pais**)
  - A função de avaliação (**fitness function**) dá valores mais altos aos melhores estados
  - Quanto melhor a avaliação de um estado, maior a probabilidade de ser seleccionado para “procriação”
  - Produz a próxima geração de estados por selecção, cruzamento e mutação

# Algoritmos Genéticos



- Fitness function (b): nº de pares de rainhas não atacantes ( $\min = 0$ ,  $\max = (8 \times 7)/2 = 28$ )
  - Probabilidade de selecção (c) em função da fitness function
    - $Ex^0 \ 24/(24+23+20+11) = 31\%$
  - Um estado pode ser seleccionado mais de uma vez


# Algoritmos Genéticos



- O ponto de cruzamento é escolhido aleatoriamente
- São criados os filhos (d)
- Depois de criado o filho,
  - Com uma probabilidade baixa independente
  - Esse filho pode sofrer mutações aleatórias (e)


# Algoritmos Genéticos:

**cruzamento** e **mutação**




**32752411**

+



**24748552**

=



**32748552**

**32748152**



# Algoritmos Genéticos

- **Há ainda muito trabalho a fazer de modo a perceber em que condições e com que parâmetros é que os algoritmos genéticos se comportam bem**