


Incerteza



Sumário

- Agentes que têm que agir com incerteza
- Probabilidades
- Inferência usando distribuições disjuntas
- Independência
- Regra de Bayes

Um agente com incerteza



Um problema muito antigo...



Tipos de Incerteza

- **Incerteza no conhecimento prévio**
E.g., no diagnóstico de uma avaria de um carro, há conhecimento que nós não sabemos;
- Ou por exemplo, no diagnóstico médico há causas de doenças que não são conhecidas (não fazem parte do conhecimento prévio do agente)

Tipos de Incerteza

- **Incerteza nas acções**
E.g., as acções são apresentadas através de um conjunto pequeno de pre-condições. Embora na realidade a lista pode ser bastante ... maior.....

Exemplo:

Plano para dar hoje a aula....

- Acordar.. vestir-me.
- Tomar pequeno almoço...
- Arrumar o computador..
- Pegar no carro..
- Vir para a aula.

Tipos de Incerteza

No entanto....

- O carro poderia ter sido roubado durante a noite
- O carro podia ter os pneus furados
- Podia ter ficado sem gásleo
- O carro poderia ter ficado sem batreria
- A porta da garagem poderia ter-se avariado
- As chaves do carro poderia ter desaparecido (por exemplo, porque o cão as comeu...)
- A minha rua estava cortada ao trânsito por causa de um contentor
- Ao descer as escadas parti uma perna...
- O computador avariou quando o liguei...

Tipos de Incerteza

No entanto....

- O carro poderia ter sido roubado durante a noite
- O carro podia ter os pneus furados
- Podia ter ficado sem gás/óleo
- O carro poderia ter ficado sem bateria
- A porta da garagem poderia ter-se avariado
- As chaves do carro poderiam ter desaparecido (por exemplo, porque o cão as comeu...)
- A minha rua estava cortada ao trânsito por causa de um contentor
- Ao descer as escadas parti uma perna...
- O computador avariou quando o liguei...

Listar todas as possibilidades não é possível... nem eficiente...

Tipos de Incerteza


- **Incerteza nas percepções**
E.g., os meus sensores não me dão informação completa sobre o mundo; por exemplo, o agente/robô não sabe com exactidão em que posição se encontra

Tipos de Incerteza

- **Incerteza nas percepções**

E.g., os meus sensores não me dão informação completa sobre o mundo: por exemplo, o

ag
po



Courtesy R. Chatila

Tipos de Incerteza

- **Incerteza no conhecimento prévio**
E.g., no diagnóstico de uma avaria de um carro, há conhecimento que nós não sabemos;
- **Incerteza nas acções**
E.g., as acções são representadas através de um conjunto pequeno de precondições. Embora na realidade a lista possa ser bastante grande ...
- **Incerteza nas percepções**
E.g., os meus sensores não me dão informação completa sobre o mundo; por exemplo, o agente/robô não sabe com exactidão em que posição se encontra

Tipos de Incerteza

- **Incerteza no conhecimento prévio**

E.g., no diagnóstico de uma avaria de um carro, há conhecimento que nós não sabemos;

O que nós chamamos incerteza é um sumário de tudo o que não pode ser explicitamente tomado em conta na base de conhecimentos do agente.

completa sobre o mundo; por exemplo, o agente/robô não sabe com exactidão em que posição se encontra

Exemplo



relação entre dorDeDentes e carieNoDente

Exemplo

~~DorDeDentes \Rightarrow CarieNoDente~~

~~DorDeDentes \Rightarrow CarieNoDente \vee Gengivite \vee
Abcesso \vee ...~~

~~CarieNoDente \Rightarrow DorDeDentes~~

Tipos de Incerteza

Origens da Incerteza:

1. **Ignorância:** (prática) nós não sabemos todas as regras, e podemos não ter a certeza acerca de um caso por não termos feito todos os testes; (teórica) a medicina ainda tem conhecimento completo sobre o domínio,
2. **Preguiça:** não queremos enumerar todas as possibilidades

Questões

- Como representar incerteza no conhecimento do agente?
- Como fazer inferência com conhecimento incerto?
- Que acções escolher tendo em conta incerteza?

Como lidar com incerteza

- De uma forma implícita:
 - Ignorando tudo o que não temos certeza sempre que possível
 - Construindo procedimentos que são robustos na forma como lidam com a incerteza
- De forma explícita:
 - Construir um modelo do mundo que captura a incerteza do seu estado, a sua dinâmica e como se liga com as observações efectuadas
 - Raciocinar acerca do efeito que as acções têm nesse modelo.

Como lidar com incerteza?

Aproximações:

1. Raciocínio por Omissão
2. Raciocínio Probabilístico

Raciocínio por Omissão

- Ideia: o mundo é em geral “normal” e as anormalidades são usualmente raras.
- Ou seja, o agente assume a normalidade em geral até que haja evidência de contrário.
- E.g., Se um agente vê um pássaro x, assume que x pode voar,
 - a não ser que haja evidência de que x é um pinguim, ou uma avestruz, ou um pássaro morto, ou um pássaro com as asas cortadas,...

Representação em Lógica

- $BIRD(x) \wedge \neg AB_F(x) \Rightarrow FLIES(x)$
- PE Muito activo nos anos 80
- BR \rightarrow Lógicas não monótonas, etc.
- BIF \rightarrow Será dado na cadeira de Representação de conhecimento e Raciocínio
- ... \rightarrow Aplicações a bases de dados

Regra de omissão: A não ser que $AB_F(Tweety)$ seja provado ser Verdade, vai-se assumir que é falso

Mas e se há regras com aspectos contraditórios?
Quais manter? Quais rejeitar?

Usar Raciocínio Probabilístico

- Expressar o “grau de crença” de um agente através de teoria de probabilidade (Probability Theory)
- A Probability Theory atribui a cada frase um valor numérico entre 0 e 1

As probabilidades permitem sumarizar a incerteza que resulta não só da nossa ignorância mas também da nossa preguiça.

Voltando ao Exemplo



Podemos dizer que há uma probabilidade de 80% do paciente ter uma cárie no dente, dado que ele apresenta uma dor de dentes.

“O paciente tem uma cárie” - verdade ou falso dependendo da interpretação do mundo

“A probabilidade do paciente ter uma cárie é 0.8” - tem a ver com as crenças do agente, que dependem das suas percepções e que constituem a “evidência” sobre a qual a probabilidade se baseia.

Como decidir o que
fazer com incerteza?

Decisão Racional: Teoria da Utilidade

- A decisão de uma agente é guiada por “preferências” entre possíveis resultados (outcomes).
- A forma de decidir em agentes racionais baseia-se na noção de “utilidade”
- Os agentes dão preferência a estados com “maior utilidade”!

Incerteza e Decisão Racional: Teoria da Decisão

Decision Theory = probability theory + utility theory

Incerteza e Decisão Racional

Função AgenteDT (*percepcao*) **devolve** *accao*

input: *percepcao*

estatico: *estado_crenças*, crenças probabilísticas acerca do
estado actual do mundo

accao, acção do agente

actualiza *estado_crenças* em função de *accao* e *percepcao*

calcular probabilidades de resultado das acções,

dado as descrições das acções e o *estado_crença*

seleccionar *accao* com maior utilidade esperada dadas as probabilidades dos resultados e a informação de utilidade

devolve *accao*

Probabilidades

- É um framework conhecido (tem uma semântica clara)
- Dá respostas a:
 - Combinação de evidências
 - Raciocínio Preditivo e de Diagnóstico
 - Lida com a incorporação de novas evidências
- É intuitivo (pelo menos para algumas pessoas!)
- Pode ser aprendido (usado em aprendizagem automática)

Noção de Probabilidade

Está relacionado com as minhas CRENÇAS

De manhã, na vinda para o Tagus, eu passo junto à A5, e verifiquei que 70% das vezes o trânsito está parado, Num dia com muita pressa para vir dar aulas, eu decido ir dar a volta por Sassoeiros, porque acredito que “o trânsito está parado na A5” com uma probabilidade de 0.7.

Interpretação associada a Frequência

- Tiro uma bola de uma saco que contém n bolas, do mesmo tamanho contendo r bolas vermelhas e s bolas amarelas.
- A probabilidade de que a proposição $A =$ “a bola é vermelha” é verdade corresponde à frequência relativa com a qual esperamos tirar uma bola vermelha
→ $P(A) = r/n$

Interpretação Subjectiva

Há muitas situações em que não há uma interpretação objectiva da frequência

- Num dia com vento, antes de me aventurar a fazer “paragliding”, eu penso “há uma probabilidade de 0.05 de eu cair e morrer”
- Ou... “tenho estudado tanto na cadeira de IA que a probabilidade de conseguir uma nota acima de 18 é de 0.8”.

Noção de Probabilidade



$$P(H) = 0.5$$

$$P(T) = 0.5$$

Noção de Probabilidade



$$P(H) = 0.5$$

$$P(T) = 0.5$$

$$P(H,H,H) = ???$$

Noção de Probabilidade



$$P(H) = 0.5$$

$$P(T) = 0.5$$

$$P(H,H,H) = 0.5*0.5*0.5= 0.125$$

Noção de Probabilidade



$$P(H) = 0.5$$

$$P(T) = 0.5$$

Lançar a moeda 4
vezes

X_i – Resultado de
lançar a moeda na
vez i

$$X_i = \{H, T\}$$

$$P(X_1=X_2=X_3=X_4) = \text{????}$$

Noção de Probabilidade



$$P(H) = 0.5$$

$$P(T) = 0.5$$

Lançar a moeda 4
vezes

X_i – Resultado de
lançar a moeda na
vez i

$$X_i = \{H, T\}$$

$$P(X_1=X_2=X_3=X_4) = P(H,H,H,H) + P(T,T,T,T) = 0.125$$

Noção de Probabilidade



$$P(H) = 0.5$$

$$P(T) = 0.5$$

Lançar a moeda 4
vezes

X_i – Resultado de
lançar a moeda na
vez i

$$X_i = \{H, T\}$$

$P(\{X_1, X_2, X_3, X_4\} \text{ contém 3 ou mais H}) = \text{????}$

Noção de Probabilidade



$$P(H) = 0.5$$

$$P(T) = 0.5$$

Lançar a moeda 4
vezes

X_i – Resultado de
lançar a moeda na
vez i

$$X_i = \{H, T\}$$

$$P(\{X_1, X_2, X_3, X_4\} \text{ contém 3 ou mais H}) = P(H, H, H, H) + P(H, H, H, T) + \\ P(H, H, T, H) + P(H, T, H, H) + P(T, H, H, H) = 5/16 = 0.3125$$

Noção de Variável Aleatória

O elemento básico da linguagem é a “**Variável aleatória**”, que pode ser vista como a parte do mundo cujo estado é inicialmente desconhecido.

Cada variável aleatória tem um domínio de valores que pode tomar.

Por exemplo:

- podemos ter uma variável aleatória “CárieNoDente” que pode ser *<true,false>*
- A variável aleatória *X* (quando lanço uma moeda) pode ser *<Head,Tail>*
- A variável aleatória *Weather* (que designa o tempo que vai estar) pode ter por exemplo *<sunny, rainy, cloudy, snowy>* como domínio

Tipos de Variáveis Aleatórias

- Variáveis Aleatórias Booleanas (Boolean Random Variables), como `Cari e NoDente`
- Variáveis Aleatórias Discretas (Discrete random variables). Por exemplo no caso do “tempo” (weather).
- Variáveis aleatórias contínuas, que tomam valores nos números reais (exemplo: a temperatura).

Variáveis Aleatórias

- Uma proposição que é verdade com uma probabilidade p e falsa com uma probabilidade $1-p$, é uma **variável aleatória** com uma distribuição $(p, 1-p)$
- Se um saco contém bolas com 3 cores possíveis – vermelho, amarelo e azul- a cor da bola que escolhermos aleatoriamente é uma variável aleatória com 3 valores possíveis.
- A distribuição de probabilidades (**probability distribution**) de uma variável aleatória X com n valores x_1, x_2, \dots, x_n é:
 (p_1, p_2, \dots, p_n)
with $P(X=x_i) = p_i$ and $\sum_{i=1, \dots, n} p_i = 1$

Proposições

- Podemos ver símbolos proposicionais como variáveis aleatórias, se assumirmos que estas têm o domínio $\langle \text{true}, \text{false} \rangle$ (variáveis aleatórias booleanas).

Exemplo

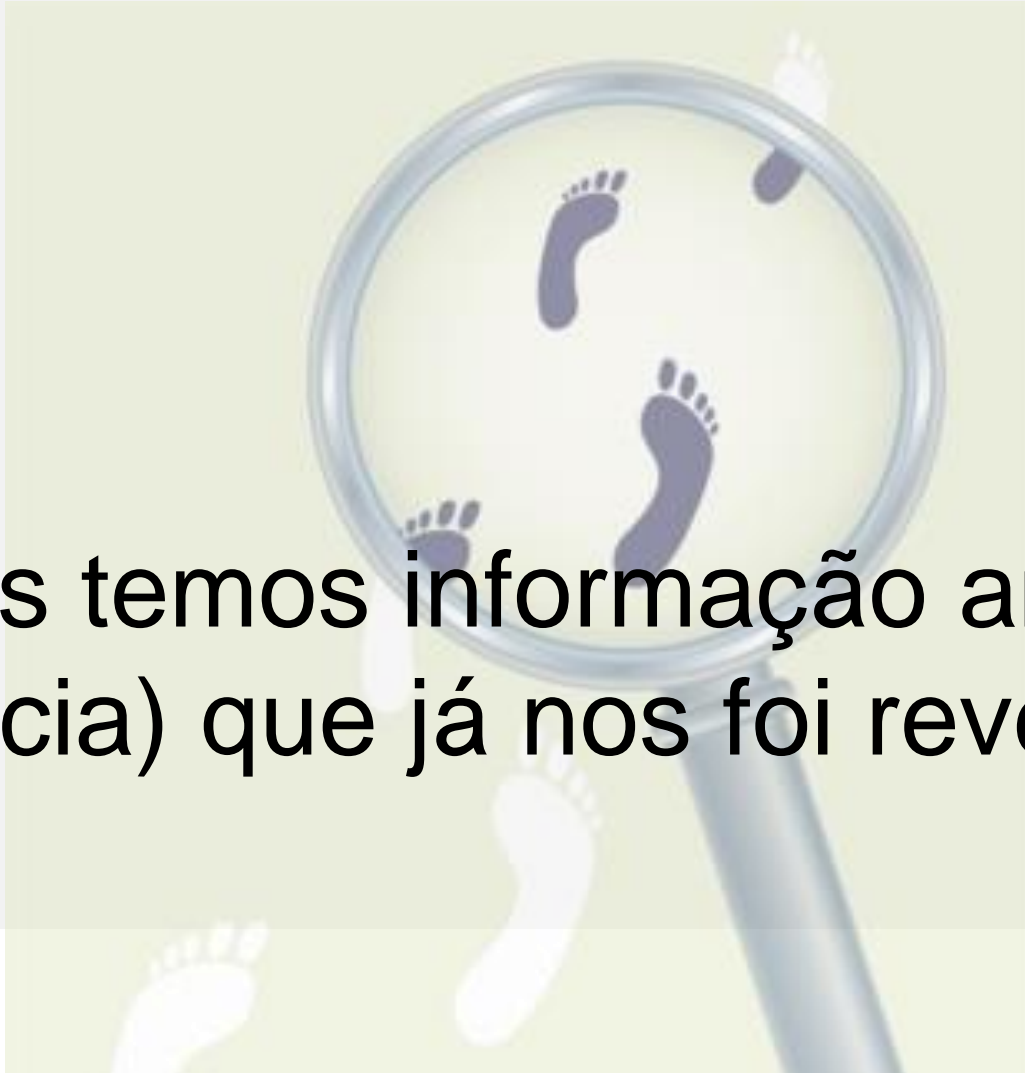
- $P(\text{carieNoDente})$ representa $P(\text{carieNoDente}=\text{true})$
- Do mesmo modo $P(\neg \text{carieNoDente})$ é uma forma de dizer $P(\text{carieNoDente}=\text{false})$

Variáveis não condicionadas

- Usa-se a notação $P(\text{carieNoDente})$ para designar uma probabilidade não condicionada (unconditional ou prior probability) para uma dada proposição
- *Ex: $P(\text{carieNoDente}) = 0.2$*

*Quer dizer que, **na ausência de qualquer outra informação**, o agente considera que a probabilidade de um paciente ter uma cavidade no dente é de 0.2 (20%)*

Probabilidade Condicional

An illustration of a magnifying glass with a silver frame and handle, positioned over a light green surface. Several footprints are visible: two dark purple ones are inside the magnifying glass's lens, while several white ones are scattered outside. The magnifying glass is tilted slightly to the right.

Por vezes temos informação anterior
(evidência) que já nos foi revelada.

Probabilidade Condicional



- $P(\text{Doubles})$ ou $P(\text{Total} = 11)$
probabilidade não
condicionada

Mas se o primeiro dado saíu 5

Probabilidade condicional
 $P(\text{Doubles} | X1=5)$

- $X1$ – valor do dado 1
- $X2$ – Valor do dado 2

Voltando ao exemplo



- $P(\text{carieNoDente}) = 0.2$

Mas....

$$P(\text{carieNoDente} \mid \text{dorDeDentes}) = 0.6$$

Probabilidade Condicional

Definição:

$$P(A|B) = P(A \cap B) / P(B)$$

- Lê-se $P(A|B)$: probabilidade de A dado B

Podemos também escrever:

$$P(A \cap B) = P(A|B) P(B)$$

Chamada : “**Product rule**”

Axiomas

1. Todas as probabilidades estão entre 0 e 1

$$0 \leq P(A) \leq 1$$

2. Proposições necessariamente verdade têm probabilidade 1, e necessariamente falsas tem probabilidade 0

$$P(\text{true}) = 1 \text{ e } P(\text{false}) = 0$$

3. A probabilidade da disjunção é:

$$P(A \vee B) = P(A) + P(B) - P(A \wedge B)$$

Exemplo



- $P(D1=\text{sunny})=0.9$
- $P(D2=\text{sunny}|D1=\text{sunny}) = 0.8$
- $P(D2=\text{rainy}|D1=\text{sunny}) = ???$



Exemplo



- $P(D1=\text{sunny})=0.9$
- $P(D2=\text{sunny}|D1=\text{sunny}) = 0.8$
- $P(D2=\text{rainy}|D1=\text{sunny}) = \mathbf{0.2}$



Exemplo



- $P(D1=\text{sunny})=0.9$
- $P(D2=\text{sunny}|D1=\text{sunny}) = 0.8$
- $P(D2=\text{rainy}|D1=\text{sunny}) = 0.2$
- $P(D2=\text{sunny}|D1=\text{rainy}) = 0.6$
- $P(D2=\text{rainy}|D1=\text{rainy}) = ???$

Exemplo



- $P(D1=\text{sunny})=0.9$
- $P(D2=\text{sunny}|D1=\text{sunny}) = 0.8$
- $P(D2=\text{rainy}|D1=\text{sunny}) = 0.2$
- $P(D2=\text{sunny}|D1=\text{rainy}) = 0.6$
- $P(D2=\text{rainy}|D1=\text{rainy}) = \mathbf{0.4}$

Exemplo



- $P(D1=\text{sunny})=0.9$
- $P(D2=\text{sunny}|D1=\text{sunny}) = 0.8$
- $P(D2=\text{rainy} \mid D1=\text{sunny}) = 0.2$
- $P(D2=\text{sunny}|D1=\text{rainy}) = 0.6$
- $P(D2=\text{rainy} \mid D1=\text{rainy}) = 0.4$

- $P(D2=\text{sunny}) = \text{?????}$

Exemplo



- $P(D1=\text{sunny})=0.9$
- $P(D2=\text{sunny}|D1=\text{sunny}) = 0.8$
- $P(D2=\text{rainy} \mid D1=\text{sunny}) = 0.2$
- $P(D2=\text{sunny}|D1=\text{rainy}) = 0.6$
- $P(D2=\text{rainy} \mid D1=\text{rainy}) = 0.4$

- $P(D2=\text{sunny}) = \mathbf{0.9*0.8 + 0.1*0.6 = 0.78}$

Exemplo



- $P(\text{Weather}=\text{sunny})=0.6$
- $P(\text{Weather}=\text{rainy})=0.1$
- $P(\text{Weather}=\text{cloudy})=0.299$
- $P(\text{Weather}=\text{snowy})=0.001$

$P(\text{Weather}) = \langle 0.6, 0.1, 0.299, 0.001 \rangle$

Exemplo



- $P(\text{Weather}=\text{sunny})=0.6$
- $P(\text{Weather}=\text{rainy})=0.1$
- $P(\text{Weather}=\text{cloudy})=0.299$
- $P(\text{Weather}=\text{snowy})=0.001$

Distribuição de
Probabilidades da
variável *Weather*

$P(\text{Weather}) = \langle 0.6, 0.1, 0.299, 0.001 \rangle$

Distribuição de Probabilidades

- Para variáveis contínuas não é possível escrever a distribuição inteira como um vector, pelo que se usa uma função de densidade de probabilidade

E quando temos várias variáveis?

$P(\textit{Weather}, \textit{carieNoDente})$



Distribuição de
Probabilidades
Conjunta (Joint
Probabilities
Distribution)

Denota as probabilidades de todas as combinações de valores da variável *Weather* e da variável *carieNoDente*

Distribuição de Probabilidade Conjunta (Joint Probability Distribution)



$$P(\text{cloudy}, \text{carieNoDente}) \\ = P(\text{cloudy} | \text{carieNoDente}) P(\text{carieNoDente})$$

Distribuição de Probabilidade Conjunta (Joint Probability Distribution)

- A distribuição de probabilidade conjunta (**joint probability distribution**) pode ser vista através de uma tabela em que cada entrada dá uma combinação de valores de X_1, \dots, X_k
- Exemplo:

	dorDeDentes	\neg dorDeDentes
carieNoDente	0.04	0.06
\neg carieNoDente	0.01	0.89

$P(\neg \text{carieNoDente} \wedge \text{dorDeDentes})$

$P(\text{carieNoDente} \wedge \neg \text{dorDeDentes})$

Distribuição de Probabilidade Conjunta (Joint Probability Distribution)

	dorDeDentes	¬dorDeDentes
carieNoDente	0.04	0.06
¬carieNoDente	0.01	0.89

- $$\begin{aligned} P(\text{carieNoDente}) &= P((\text{dorDeDentes} \wedge \text{carieNoDente}) \vee \\ &\quad (\neg \text{dorDeDentes} \wedge \text{carieNoDente})) \\ &= P(\text{dorDeDentes} \wedge \text{carieNoDente}) + \\ &\quad P(\neg \text{dorDeDentes} \wedge \text{carieNoDente}) \\ &= 0.04 + 0.06 = 0.1 \end{aligned}$$

“Probabilidade Marginal” de carieNoDente (soma dos valores da linha)

Marginalização

Marginalização- soma das probabilidades para cada um dos valores possíveis das outras variáveis, tirando-as portanto da equação

Regra de Marginalização para qualquer conjunto de variáveis Y e Z

$$P(Y) = \sum_{Z \in Z} P(Y, Z)$$

Ou seja, a soma de todas as combinações de valores possíveis para o conjunto de variáveis Z

Distribuição de Probabilidade Conjunta (Joint Probability Distribution)

	dorDeDentes	¬dorDeDentes
carieNoDente	0.04	0.06
¬carieNoDente	0.01	0.89

- $$\begin{aligned} P(dorDeDentes) &= P((dorDeDentes \wedge carieNoDente) \vee \\ &\quad (dorDeDentes \wedge \neg carieNoDente)) \\ &= P(dorDeDentes \wedge carieNoDente) + \\ &\quad P(dorDeDentes \wedge \neg carieNoDente) \\ &= 0.04 + 0.01 = 0.05 \end{aligned}$$

“Probabilidade Marginal” de dorDeDentes (soma dos valores da coluna)

Distribuição de Probabilidade Conjunta (Joint Probability Distribution)

	dorDeDentes	¬dorDeDentes
carieNoDente	0.04	0.06
¬carieNoDente	0.01	0.89

- $P(dorDeDentes \vee carieNoDente)$
 $= P((dorDeDentes \wedge carieNoDente) \vee (dorDeDentes \wedge \neg carieNoDente)$
 $\quad \vee (\neg dorDeDentes \wedge carieNoDente))$
 $= 0.04 + 0.01 + 0.06 = 0.11$

Condicionização

Condicionização (conditioning) - soma das probabilidades para cada um dos valores possíveis das outras variáveis, tirando-as portanto da equação mas envolvendo probabilidades condicionais

Regra de condicionização para qualquer conjunto de variáveis Y e Z

$$P(Y) = \sum_{z \in Z} P(Y|z) P(z)$$

Distribuição de Probabilidade Conjunta (Joint Probability Distribution)

	dorDeDentes	¬dorDeDentes
carieNoDente	0.04	0.06
¬carieNoDente	0.01	0.89

- $P(\text{carieNoDente} \mid \text{DorDeDentes}) =$
 $P(\text{carieNoDente} \wedge \text{DorDeDentes}) / P(\text{DorDeDentes})$
- $P(\text{carieNoDente} \wedge \text{DorDeDentes}) = ?$
- $P(\text{DorDeDentes}) = ?$
- $P(\text{carieNoDente} \mid \text{DorDeDentes}) = 0.04/0.05 = 0.8$

Distribuição de Probabilidade Conjunta (Joint Probability Distribution)



	dorDeDentes		¬dorDeDentes	
	Detecta	¬ Detecta	Detecta	¬ Detecta
carieNoDente	0.108	0.012	0.072	0.008
¬ carieNoDente	0.016	0.064	0.144	0.576

Exemplos

	dorDeDentes		¬dorDeDentes	
	detecta	¬ detecta	detecta	¬ detecta
carieNoDente	0.108	0.012	0.072	0.008
¬ carieNoDente	0.016	0.064	0.144	0.576

$$P(\textit{carieNoDente} / \textit{dorDeDentes}) = \text{????}$$

Exemplos

	dorDeDentes		¬dorDeDentes	
	detecta	¬ detecta	detecta	¬ detecta
carieNoDente	0.108	0.012	0.072	0.008
¬ carieNoDente	0.016	0.064	0.144	0.576

$$P(\text{carieNoDente} / \text{dorDeDentes}) =$$

$$P(\text{carieNoDente} \wedge \text{dorDeDentes}) / P(\text{dorDeDentes}) = \\ 0.108 + 0.012 / (0.108 + 0.012 + 0.016 + 0.064) = 0.6$$

Independência



Independência

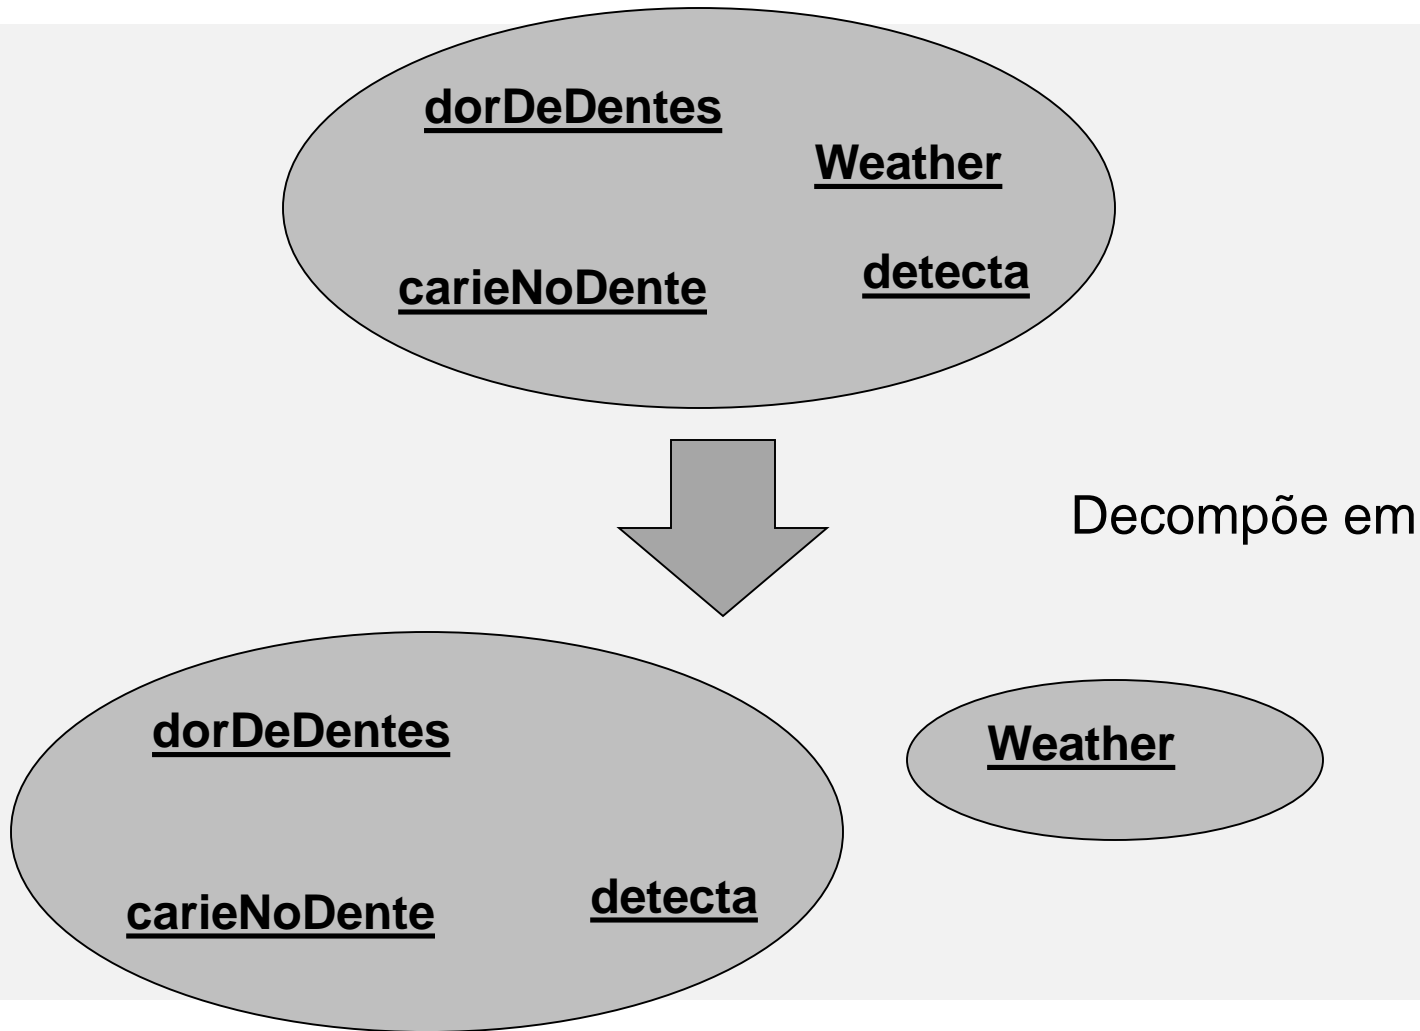
$$P(\text{dorDeDentes}, \text{detecta}, \text{carieNoDente}, \text{rainy}) = \\ P(\text{rainy} \mid \text{dorDeDentes}, \text{detecta}, \text{carieNoDente}) * \\ P(\text{dorDeDentes}, \text{detecta}, \text{carieNoDente})$$

$$P(\text{rainy} \mid \text{dorDeDentes}, \text{detecta}, \text{carieNoDente}) = \\ P(\text{rainy})$$

Ou seja:

$$P(\text{dorDeDentes}, \text{detecta}, \text{carieNoDente}, \text{rainy}) = \\ P(\text{rainy}) * P(\text{dorDeDentes}, \text{detecta}, \text{carieNoDente})$$

Independência



Independência

A e B são independentes se e só se:

$$P(A|B) = P(A) \text{ and } P(B|A) = P(B) \text{ and } P(A, B) = P(A)P(B)$$

Regra de Bayes

- $P(A \wedge B) = P(A|B) P(B)$
 $= P(B|A) P(A)$

Ou seja:

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$



Thomas Bayes, 1702(?)–1761

Uso da Regra de Bayes: combinar evidências


$$P(\text{causa}|\text{efeito}) = \frac{P(\text{efeito}|\text{causa}) P(\text{causa})}{P(\text{efeito})}$$

Permite fazer diagnóstico.

O médico sabe $P(\text{sintomas} | \text{doença})$ e o que queremos fazer é $P(\text{doença} | \text{sintomas})$

Uso da Regra de Bayes

Exemplo



- Dificuldade de mover o pescoço (pode ser causada por meningite)
- Meningite causa dificuldade de mover o pescoço – 50%
- Sabemos por dados que um paciente tem meningite $1/50.000$
- Sabemos que $1/20$ pessoas têm problemas de pescoço...

Uso da Regra de Bayes

Exemplo



- $P(pp/m) = 0.5$
- $P(m) = 1/50.000$
- $P(pp) = 1/20$

- Meningite causa dificuldade de mover o pescoço – 50%
- Sabemos por dados que um paciente tem meningite 1/50.000
- Sabemos que 1/20 pessoas têm problemas de pescoço...

Como tirar conclusões sobre um paciente que tem dificuldades de mover o pescoço?

Uso da Regra de Bayes

Exemplo



- Meningite causa dificuldade de mover o pescoço – 50%
- Sabemos por dados que um paciente tem meningite 1/50.000
- Sabemos que 1/20 pessoas têm problemas de pescoço...

- $P(pp/m) = 0.5$
- $P(m) = 1/50.000$
- $P(pp) = 1/20$

Como tirar conclusões sobre um paciente que tem dificuldades de mover o pescoço?

- $P(m/pp) = p(pp|m) p(m) / p(pp) = (0.5 * 1/50.000) / 1/20 = 0.0002$
- Ou seja, só um em 5000 dos pacientes com dificuldades de mover o pescoço têm meningite...

Normalização

- $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$
- $P(\neg A|B) = \frac{P(B|\neg A)P(\neg A)}{P(B)}$

Calcular $P(B)$ é complicado. Podemos chamar:

$$P'(A|B) = P(B|A)P(A)$$

$$P'(\neg A|B) = P(B|\neg A)P(\neg A)$$

Ou seja:

$$P(A|B) = 1/P(B) * P'(A|B) = \eta P'(A|B)$$

$$P(\neg A|B) = 1/P(B) * P'(\neg A|B) = \eta P'(\neg A|B)$$

Como $P(A|B) + P(\neg A|B) = 1$

$$\eta = 1 / (P'(A|B) + P'(\neg A|B))$$

Normalização

- $$P(A|B) = \frac{P(B|A)P(A)}{P(B|A)P(A) + P(B|\neg A)P(\neg A)}$$
- Versão normalizada da Regra de Bayes
 - Sem qualquer referência a $P(B)$

Sumário

- Agentes que têm que agir com incerteza
- Probabilidades
- Inferência usando distribuições disjuntas
- Independência
- Regra de Bayes